

# M6120 Lineární statistické modely II

Projekt/Domací úloha

Michal Červenka (518670)



B-MAT Matematika

Přírodovědecká fakulta, Masarykova Univerzita

27. května 2024

## Obsah

Řešení příkladu 1	1
Řešení příkladu 2	3
Řešení příkladu 3	7

## Řešení příkladu 1

Uvažujme lineární model ve tvaru

$$Y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 \mathbb{I}_M\{i\} + \epsilon_i, \quad \epsilon_i \sim N(0, \sigma^2)$$

pro  $i = 1, 2, \dots, n$ , kde  $\mathbb{I}_M\{i\}$  označuje indikátorovou funkci nějaké pevně dané množiny  $M$ , tj.

$$\mathbb{I}_M\{i\} = \begin{cases} 1 & i \in M, \\ 0 & i \notin M. \end{cases}$$

Podle Scheffého věty platí

$$\Pr \left( \left\{ \mathbf{b}^\top (\mathbf{A}\hat{\beta} - \mathbf{A}\beta) \right\}^2 \leq m F_{1-\alpha}(m, n-p) \hat{\sigma}^2 \mathbf{b}^\top \mathbf{A} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{A}^\top \mathbf{b} \right) = 1 - \alpha$$

pro všechna  $\mathbf{b} \in \mathbb{R}^m$ , kde  $\mathbf{A} \in \mathbb{R}^{m \times p}$ . V případě našeho modelu je  $m = 3$ ,  $p = 4$  a  $\mathbf{b} = (1, x, x^2)^T$ . Odvození tvaru pásu spolehlivosti rozdělíme do dvou částí, a to na případ, kdy  $i \in M$  a kdy  $i \notin M$ . V závislosti na této situaci se bude měnit matice  $\mathbf{A}$ .

Začneme se situací, kdy  $i \in M$ . V tomto případě je matice  $\mathbf{A}$  ve tvaru

$$\mathbf{A} = \begin{pmatrix} 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix}.$$

Nyní dosadíme do Scheffého věty a začneme odvozovat pás spolehlivosti. Po dosazení dostaváme

$$\Pr(\{\hat{\beta}_0 + \hat{\beta}_3 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 - (\beta_0 + \beta_3 + \beta_1 x + \beta_2 x^2)\}^2 \leq 3 \cdot F_{1-\alpha}(3, n-4) \hat{\sigma}^2 (1, x, x^2, 1) (\mathbf{X}^\top \mathbf{X})^{-1} (1, x, x^2, 1)^T) = 1 - \alpha.$$

Odmocníme výraz uvnitř  $\Pr$ , čímž dostaneme

$$\Pr(\hat{\beta}_0 + \hat{\beta}_3 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 - (\beta_0 + \beta_3 + \beta_1 x + \beta_2 x^2) \leq \pm \sqrt{3 \cdot F_{1-\alpha}(3, n-4) \hat{\sigma}^2 (1, x, x^2, 1) (\mathbf{X}^\top \mathbf{X})^{-1} (1, x, x^2, 1)^T}) = 1 - \alpha.$$

Označme  $y = \beta_0 + \beta_3 + \beta_1 x + \beta_2 x^2$ . Tvar pásu spolehlivosti odvozeného z Scheffého věty pro situaci  $i \in M$  s pravděpodobností pokrytí  $100 \cdot (1 - \alpha) \%$  je

$$y \geq \hat{\beta}_0 + \hat{\beta}_3 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 - \sqrt{3 \cdot F_{1-\alpha}(3, n-4) \hat{\sigma}^2 (1, x, x^2, 1) (\mathbf{X}^\top \mathbf{X})^{-1} (1, x, x^2, 1)^T},$$

$$y \leq \hat{\beta}_0 + \hat{\beta}_3 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 + \sqrt{3 \cdot F_{1-\alpha}(3, n-4) \hat{\sigma}^2 (1, x, x^2, 1) (\mathbf{X}^\top \mathbf{X})^{-1} (1, x, x^2, 1)^T}.$$

Situaci, kdy  $i \in M$  máme vyřešenou. Zaměřme se nyní na situaci, kdy  $i \notin M$ . Matice  $\mathbf{A}$  bude v tomto případě v následujícím tvaru

$$\mathbf{A} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix}.$$

Odvození pásu spolehlivosti pro tuto situaci provedeme analogicky jako v předchozím případě. Prvně dosadíme do Scheffého věty, čímž dostaneme

$$\Pr(\{\hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 - (\beta_0 + \beta_1 x + \beta_2 x^2)\}^2 \leq 3 \cdot F_{1-\alpha}(3, n-4) \hat{\sigma}^2 (1, x, x^2, 0) (\mathbf{X}^\top \mathbf{X})^{-1} (1, x, x^2, 0)^T) = 1 - \alpha.$$

Odmocníme výraz uvnitř Pr, čímž dostaneme

$$\Pr(\hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 - (\beta_0 + \beta_1 x + \beta_2 x^2) \leq \pm \sqrt{3 \cdot F_{1-\alpha}(3, n-4) \hat{\sigma}^2(1, x, x^2, 0)(X^T X)^{-1}(1, x, x^2, 0)^T}) = 1 - \alpha.$$

Označme  $y = \beta_0 + \beta_1 x + \beta_2 x^2$ . Tvar pásu spolehlivosti odvozeného z Scheffého věty pro situaci  $i \notin M$  s pravděpodobností pokrytí  $100 \cdot (1 - \alpha) \%$  je

$$y \geq \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 - \sqrt{3 \cdot F_{1-\alpha}(3, n-4) \hat{\sigma}^2(1, x, x^2, 0)(X^T X)^{-1}(1, x, x^2, 0)^T},$$

$$y \leq \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 + \sqrt{3 \cdot F_{1-\alpha}(3, n-4) \hat{\sigma}^2(1, x, x^2, 0)(X^T X)^{-1}(1, x, x^2, 0)^T}.$$

## Řešení příkladu 2

(a) Najděte vhodný lineární regresní model pro popis závislosti úspěšnosti studentů na délce přípravy a zařazení skupiny. V následujících bodech pracujte s tímto modelem

Budeme uvažovat dva modely. Jeden z nich bude obsahovat interakci a druhý nikoliv a následně rozhodneme, který je více vhodný. Podívejme se na jednotlivé modely.

```
1 # Model bez interakce
2 mod1 <- lm(data = data, uspesnost ~ hodiny + skupina)
3 # Model s interkací
4 mod2 <- lm(data = data, uspesnost ~ hodiny + skupina + skupina:hodiny)
```

Nyní se podívejme podrobněji na model bez interakce.

Call:

```
lm(formula = uspesnost ~ hodiny + skupina, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-10.2601	-4.4194	-0.9404	4.3164	17.0555

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	-5.1396	1.3841	-3.713	0.000342 ***
hodiny	4.7798	0.1075	44.458	< 2e-16 ***
skupinaB	-4.9704	1.2372	-4.017	0.000116 ***
---				
Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'
	0.1	'	'	1

Residual standard error: 6.186 on 97 degrees of freedom

Multiple R-squared: 0.9536, Adjusted R-squared: 0.9526

F-statistic: 996 on 2 and 97 DF, p-value: < 2.2e-16

Můžeme si povšimnout, že všechny koeficienty modelu bez interakce jsou statisticky významné na hladině významnosti  $\alpha = 0.05$ , a tedy tento model vypadá slabě. Zaměřmě se nyní na model s interkací.

Call:

```
lm(formula = uspesnost ~ hodiny + skupina + skupina:hodiny, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-10.3059	-4.4559	-0.9882	4.6161	16.4528

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	-4.2796	1.8542	-2.308	0.0231 *
hodiny	4.6936	0.1637	28.664	<2e-16 ***
skupinaB	-6.4894	2.5013	-2.594	0.0110 *

```

hodiny:skupinaB    0.1521      0.2175     0.699     0.4860
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.203 on 96 degrees of freedom
Multiple R-squared:  0.9538,   Adjusted R-squared:  0.9524
F-statistic: 660.7 on 3 and 96 DF,  p-value: < 2.2e-16

```

V modelu s interakcí je koeficient u interakce proměnné skupina a hodiny statisticky nevýznamný na hladině významnosti  $\alpha = 0.05$ , a proto volíme jednodušší model, a tedy ten bez interakce, v našem značení mod1. Můžeme si povšimnout, že oba modely mají adjustované  $R^2$  blízké k hodnotě 0.96, a tedy jsme našli velmi vhodné modely, jelikož vysvětlují velkou část variability našich dat.

(b) Pro každou skupinu zvlášť sestrojte konfidenční pás spolehlivosti s pravděpodobností pokrytí 95 %

```

1 xx <- seq(0, 20, by = 0.1)
2 # Matice A pro skupinu A
3 A <- rbind(c(1, 0, 0), c(0, 1, 0))
4 # Odhady koeficientů modelu bez interakce
5 beta_hat <- mod1$coefficients
6 # Hodnoty parametrů
7 m <- 2
8 p <- 3
9 n <- length(data$hodiny)
10 # Odhad kovarianční matice modelu bez interakce
11 vcov_mod1 <- vcov(mod1)
12 # Příslušní F-kvantil
13 F_kvantil <- qf(0.95, m, n-p)
14
15 # Výpočet dolní a horní hranice pásu spolehlivosti pro skupinu A
16 # Skupina A - dolní hranice pásu spolehlivosti
17 pas_skupina_A_lower <- numeric(length(xx))
18 for (i in seq_along(xx)) {
19   b <- c(1, xx[i])
20   pas_skupina_A_lower[i] <- beta_hat[1] + beta_hat[2] * xx[i] -
21     sqrt(m * F_kvantil * t(b) %*% A %*% vcov_mod1 %*% t(A) %*% b)
22 }
23 # Skupina A - horní hranice pásu spolehlivosti
24 pas_skupina_A_upper <- numeric(length(xx))
25 for (i in seq_along(xx)) {
26   b <- c(1, xx[i])
27   pas_skupina_A_upper[i] <- beta_hat[1] + beta_hat[2] * xx[i] +
28     sqrt(m * F_kvantil * t(b) %*% A %*% vcov_mod1 %*% t(A) %*% b)
29 }
30
31 # Výpočet dolní a horní hranice pásu spolehlivosti pro skupinu B
32 # Změna matice pro skupinu B
33 A <- rbind(c(1, 0, 1), c(0, 1, 0))
34

```

```

35 # Skupina B - dolní hranice pásu spolehlivosti
36 pas_skupina_B_lower <- numeric(length(xx))
37 for (i in seq_along(xx)) {
38   b <- c(1, xx[i])
39   pas_skupina_B_lower[i] <- (beta_hat[1] + beta_hat[3]) + beta_hat[2] * xx[i] -
40     sqrt(m * F_kvantil * t(b) %*% A %*% vcov_mod1 %*% t(A) %*% b)
41 }
42 # Skupina B - horní hranice pásu spolehlivosti
43 pas_skupina_B_upper <- numeric(length(xx))
44 for (i in seq_along(xx)) {
45   b <- c(1, xx[i])
46   pas_skupina_B_upper[i] <- (beta_hat[1] + beta_hat[3]) + beta_hat[2] * xx[i] +
47     sqrt(m * F_kvantil * t(b) %*% A %*% vcov_mod1 %*% t(A) %*% b)
48 }
```

(c) Odhadněte (bodově i intervalově) průměrnou úspěšnost studenta skupiny B, který se učil půl hodiny

```

      fit dolni_hranice horni_hranice
1 -7.720058      -10.3885      -5.05162
```

(d) Vypočtěte simultánní intervalové odhad střední hodnoty úspěšnosti pro studenty skupiny A, kteří se učili 5, 10 a 15 hodin. Zvolte hladinu významnosti  $\alpha = 0,05$  a využijte Bonferroniho adjustaci

```

1 # Hodnoty hodiny = 5, skupina = A
2 IS_1
```

```
[1] 16.26095 21.25757
```

```

1 # Hodnoty hodiny = 10, skupina = A
2 IS_2
```


```
[1] 40.52675 44.78945
```

```

1 # Hodnoty hodiny = 15, skupina = A
2 IS_3
```

```
[1] 64.05215 69.06172
```


- (e) Zakreslete výsledky z předchozích bodů do jednoho obrázku. Tj. vykreslete bodový graf pozorování, přidejte křivky vašeho modelu, zvýrazněte konfidenční pásy spolehlivosti a požadované intervalové odhady i predikce.



Obrázek 1: Regresní přímky modelu mod1 pro obě skupiny

## Řešení příkladu 3

- (a) Vykreslete krabicové diagramy popisující úbytek hmotnosti v závislosti na typu diety a pohlaví. Vytvořte také krabicové diagramy v závislosti pouze na typu diety. Všechny diagramy vložte vedle sebe do jednoho obrázku, abyste je mohli porovnat mezi sebou. Do „krabic“ přidejte zářezy, nastavte, aby jejich šířka odpovídala propočně rozsahům a dokreslete do nich aritmetické průměry jako červené body



Obrázek 2: Boxploty úbytku váhy pro jednotlivé typy diet a pohlaví

- (b) Modelujte závislost střední hodnoty úbytku hmotnosti na typu diety a pohlaví. Vyzkoušejte různé varianty složitosti modelu: (1) model se vzájemnou interakcí obou faktorů, (2) model bez interakce a (3) model bez vlivu proměnné gender. Vyberte ten nejhodnější z nich a své rozhodnutí zdůvodněte a podpořte příslušným výstupem.

Prvně sestavme požadované modely (1) až (3).

```

1 mod1 <- lm(data = diet, weight.loss ~ gender + diet.type + diet.type:gender)
2 mod2 <- lm(data = diet, weight.loss ~ gender + diet.type)
3 mod3 <- lm(data = diet, weight.loss ~ diet.type)

```

Nyní provedeme porovnání modelů, tj. budeme zjišťovat, zda se od sebe modely statisticky významně liší na hladině významnosti  $\alpha = 0.05$ .

```

1 anova(mod1, mod2)

```

Analysis of Variance Table

```

Model 1: weight.loss ~ gender + diet.type + diet.type:gender
Model 2: weight.loss ~ gender + diet.type
  Res.Df   RSS Df Sum of Sq    F Pr(>F)
1     70 376.33
2     72 410.23 -2   -33.904 3.1532 0.04884 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Na základě výstupu vidíme, že model s oběma kategoriemi a jejich vzájemnou interakcí se liší od modelu s oběma kategoriemi, ale bez interakce. Vzhledem k tomu, že mod3 je podmodelem modelu mod2, tak zvolíme nejsložitější model, a tedy model mod3 s oběma kategoriemi "gender" a "diet.type" a jejich vzájemnou interakcí. Nezanedbatelnost interakce mezi typem diety a pohlavím nám již naznačily boxploty v (a). Můžeme si povšimnout, že úbytek váhy pro jednotlivé diety se liší v závislosti na pohlaví.

- (c) Pro vámi vybraný model model z (b) vypište do tabulky odhady středních hodnot úbytku hmotnosti pro jednotlivé skupiny (tj. v případě modelu (1) skupiny symbolicky zapíšeme jako f.A, f.B, f.C, m.A, m.B a m.C, ale např. v případě modelu (3) uvažujme pouze skupiny A, B a C).

Tabulka 1: Odhady středních hodnot úbytku hmotnosti pro jednotlivé skupiny

Skupina	Odhad střední hodnoty
f.A	3.050000
f.B	2.607143
f.C	5.880000
m.A	3.650000
m.B	4.109091
m.C	4.233333

- (d) Pro model (1) z (b) vykreslete do grafu zvlášť pro ženy (červená lomená čára) a zvlášť pro muže (modrá lomená čára) odhadnuté střední hodnoty úbytku hmotnosti pro všechny druhy diet. Na ose x budou úrovně faktoru diet.type a na ose y úbytek hmotnosti. Uveďte také, jak získáte jednotlivé odhady středních hodnot pomocí příslušných koeficientů modelu.


Prvně se podívejme, jak vypočítat jednotlivé odhady úbytku hmotnosti pro všechny diety a jednotlivá pohlaví. Pro přehlednost se podívejme na summary příslušného modelu, respektive na odhadu jeho koeficientů.

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	3.0500000	0.6196848	4.9218572	5.488725e-06
genderMale	0.6000000	0.9600115	0.6249925	5.340081e-01
diet.typeB	-0.4428571	0.8763666	-0.5053332	6.149123e-01
diet.typeC	2.8300000	0.8616367	3.2844468	1.597680e-03
genderMale:diet.typeB	0.9019481	1.3395411	0.6733261	5.029569e-01
genderMale:diet.typeC	-2.2466667	1.3145499	-1.7090767	9.186713e-02

Když už známe jednotlivé odhady koeficientů, respektive jejich pořadí, tak provedeme požadované výpočty.

```
1 # Odhady koeficientů
2 beta_hat <- mod1$coefficients
3 weight_loss_F_A <- beta_hat[1] # Žena s dietou A
4 weight_loss_F_B <- beta_hat[1] + beta_hat[3] # Žena s dietou B
5 weight_loss_F_C <- beta_hat[1] + beta_hat[4] # Žena s dietou C
6 weight_loss_M_A <- beta_hat[1] + beta_hat[2] # Muž s dietou A
7 weight_loss_M_B <- beta_hat[1] + beta_hat[2] + beta_hat[3] + beta_hat[5] # Muž s dietou B
8 weight_loss_M_C <- beta_hat[1] + beta_hat[2] + beta_hat[4] + beta_hat[6] # Muž s dietou C
```

Nyní budeme výpočty vizualizovat pomocí lomenných čar.



Obrázek 3: Lomenné čáry odhadnutých úbytků váhy v závislosti na pohlaví a typu diety